

PJE : Prédisez les infractions de stationnement -Egis- Projet data machine learning

Belali Bahaaeddine

Fabre Jules


Sanchez Chanelle

Introduction et Contextualisation



Communication Mairie commune Tonerre (89)

Répartitions des contraventions en 2023 en France



Le problème métier : Le taux d'infraction n'est pas uniforme. Envoyer des scan-cars au hasard est inefficace.
Chiffre clé : Les données traitées représentent plus de 6 millions de lignes


Objectifs du travail

- Dépasser le benchmark Corrélation de Spearman de 0.197
- Identifier les variables prédictives les plus influentes (Heure ? Météo ? Zone ?).
- Fournir un modèle capable de classer les zones par risque d'infraction.

Problématisation

- Comment transformer des coordonnées GPS brutes et des données environnementales hétérogènes en un indicateur de probabilité d'infraction fiable ?
- Gérer la non-linéarité des comportements humains (ex: l'influence de la pluie couplée à l'heure de pointe)

Méthodologie



Travail réalisé

1^{ère} étape : collecte et Nettoyage

Nettoyage :

- Séparation du ratio d'infraction avec de la DF principal
- Nettoyage des lignes avec données manquantes (NaN)
- Enregistrement de d'un fichier « clean » en csv

Fichier data_cleaner.py

Filtrage :


- Géographique : on enlève les données aberrante (latitude et longitude)
- Nombre de véhicule : on ne garde que les zones >45 effractions (total_count)

Fichier data_filtre.py


6 M => 120k entrées

Travail réalisé

Visualisation




Longitude en fonction de la latitude



Coordonnées parallèles

Travail réalisé

2^{ème} étape : Ingénierie des variables



On identifie les caractéristiques qui influence le plus le taux d'effraction

- Latitude
- Longitude
- Cluster
- Month
- Hour
- Day

Travail réalisé

3^{ème} étape : Apprentissage et Test

- Algorithme retenu: XGBoost Regressor (Decision Tree Séquentiel)
- Estimation du score (métrique de Spearman) sur une partie de X_train

Hyperparamètres finaux:

- n_estimator = 250
- l_r = 0.05
- Max depth = 7
- Random_state = 42

Score final estimé:
0.4674 (over-fitting)


Score final :

Xb	V3	0,41150751324256823
----	----	---------------------

4^{ème} étape : Définir un chemin optimal pour le passage des scan-car

Transformation des 120k coordonnées (lat/long) en 200 clusters :

- Réduit la complexité spatiale
- Priorisation en fonction du nombre d'effractions
- Adaptable a la taille de la flotte de scan-car



Conclusion

Score final :

25	10 décembre 2025 16:52	bayuardi30	0,4131
26	14 octobre 2025 13:14	Sadou	0,4052

26eme place au classement
général

Take-away:

- Quantité de données $\neq$ Qualité
- Toutes les paramètres n'ont pas la même influence